CHUPAPIS · NUCLEAR IT HACK 2026

MeowScribe

Нейро-стенографист: речь превращается в текст с говорящими и таймкодами. Полностью на устройстве.



ГЛАВНЫЙ ПРИНЦИП

Всё на устройстве. Ни байта в облако.

Распознавание речи, разделение по говорящим и локальная LLM работают офлайн. В приложении даже нет разрешения на интернет — все модели внутри APK. Проверено на эмуляторе с 4 ГБ памяти.

ПАЙПЛАЙН

Как кот слушает

01

VAD

Silero отрезает тишину, длинные куски режем по самой тихой точке

02

Диаризация

pyannote + голосовые эмбеддинги CAM++: кто из собеседников говорит

03

ASR

GigaAM v3 для русского и Parakeet для английского, сразу с пунктуацией

04

Склейка

Слова → реплики с таймкодами; поддакивания отдельно, предложение сверяется по голосу

05

LLM

Qwen 0.8B пишет название и главные пункты — не меняя ни одного слова

Модели грузятся по очереди и выгружаются после каждой стадии · sherpa-onnx и llama.cpp на CPU

МЕТРИКИ

Что получилось

6,7 % — **WER с пунктуацией** на русских диалогах. Без учёта пунктуации — 3,4 %

0,30 — **RTF** на эмуляторе с 4 ГБ RAM: 20-минутный подкаст — за 6 минут, пик памяти около 300 МБ

9,5 % — **DER** по репликам на тех же диалогах; на записях с 2–4 спикерами — 5,6 %

Качество — Python-стенд bench/ с тем же пайплайном · DER по репликам, collar 0,25 с · скорость — само приложение на эмуляторе

РЕСЁРЧ

Каждое решение — через замер

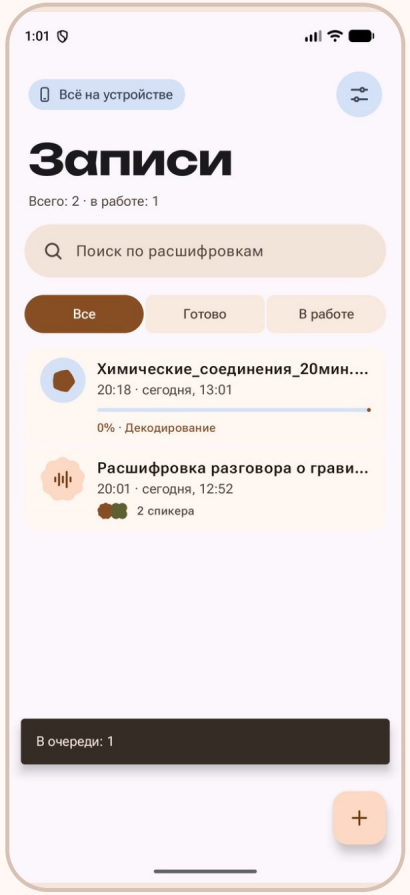
Что сделали	Где мерили	Было → стало
GigaAM v3 с пунктуацией вместо Zipformer	русские диалоги	WER 23,6 → 7,0 %
Сегментация pyannote в fp32 вместо int8	русские диалоги	DER 11,3 → 6,9 %
Нарезка длинных кусков речи по самой тихой точке	диалоги на фоне гула голосов	WER 34 → 17 %
Спикер целого предложения — по голосу	2–4 спикера	DER 8,0 → 5,6 %
Склейка мелких «осколков» спикеров	живые совещания AMI	DER 28,6 → 27,5 %

9 наборов: чистые диалоги, тихо, перегруз, гул, дальнее поле, AMI · сравнили 5 моделей ASR, 4 эмбеддинга, 3 LLM · всё в bench/README.md

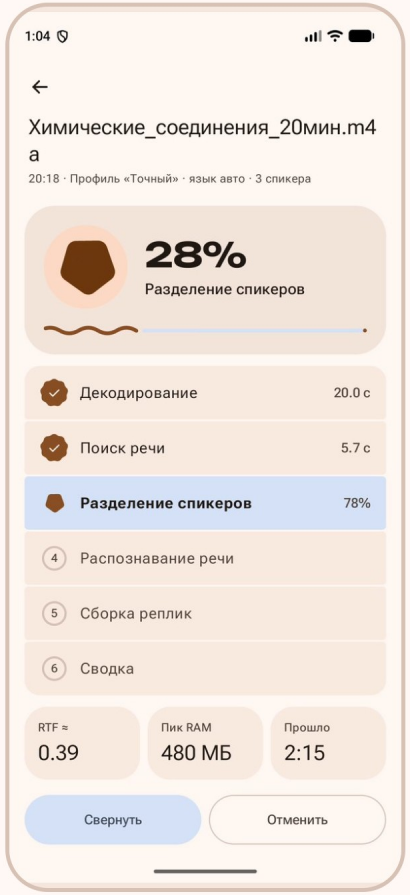
ПРИЛОЖЕНИЕ · 1

От файла до текста

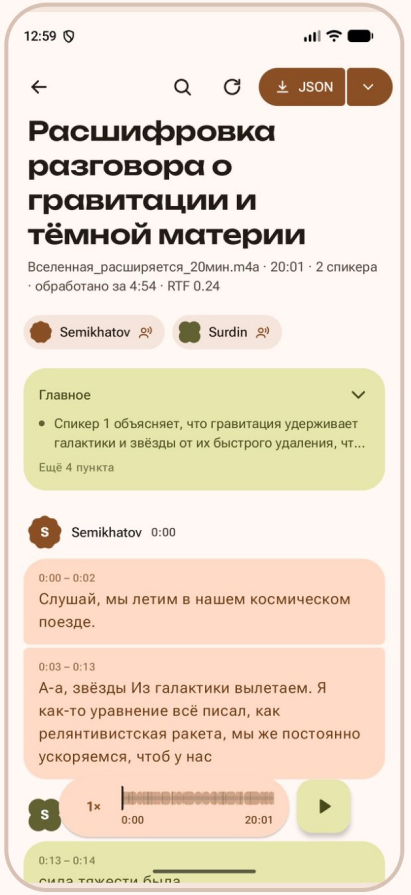
Импорт любого аудио, очередь в фоне, прогресс по стадиям. Приложение можно свернуть.



Очередь записей



Стадии, RTF и пик памяти

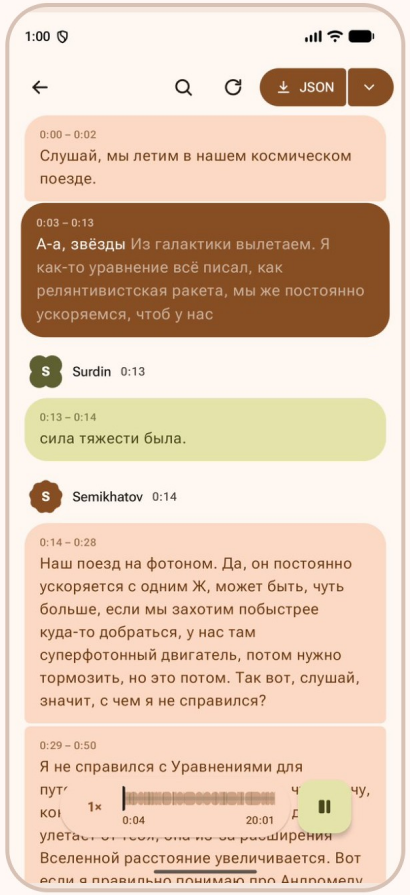


Реплики по спикерам с таймкодами

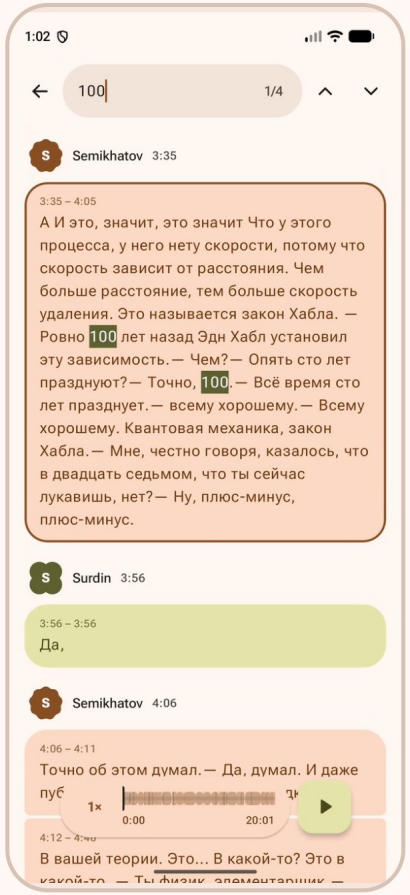
ПРИЛОЖЕНИЕ · 2

Слушай, ищи, забирай

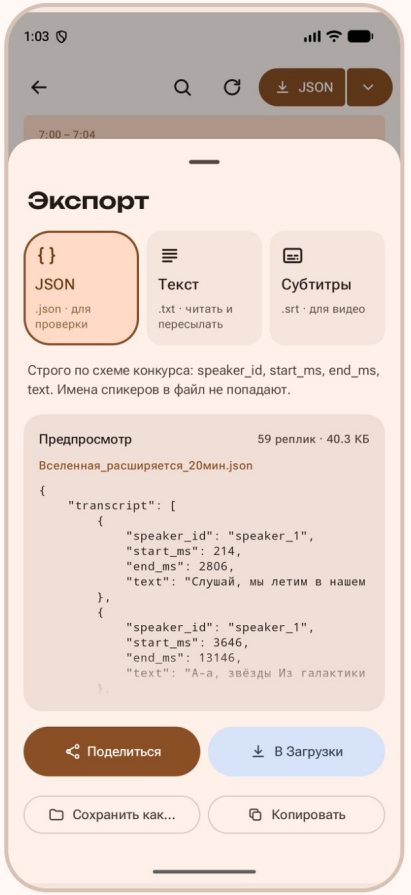
Слово подсвечивается при воспроизведении, тап по реплике — переход в аудио. Экспорт строго по схеме ТЗ.



Подсветка текущего слова



Поиск по тексту

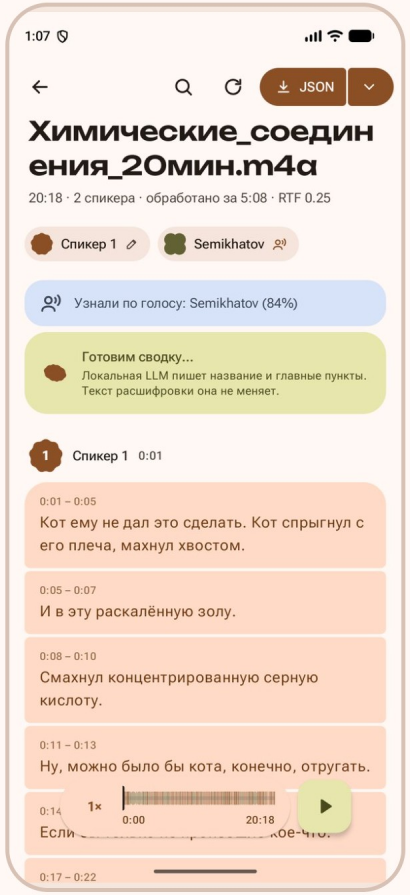


JSON по схеме, TXT, SRT

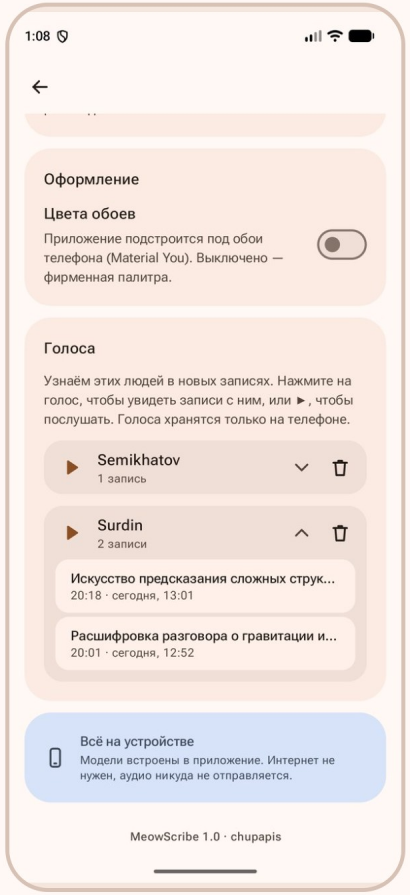
ПРИЛОЖЕНИЕ · 3

Помнит голоса

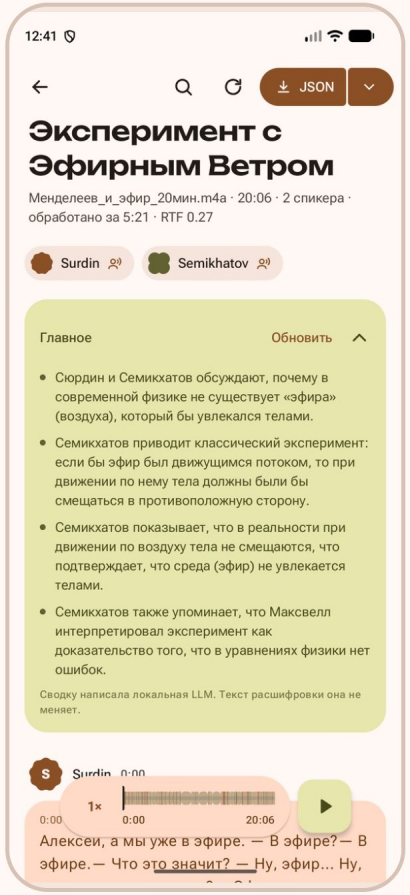
Подписали спикера с «Запомнить голос» — в следующих записях приложение узнаёт его само. Голоса хранятся только на телефоне.



«Узнали по голосу» в новой записи



База голосов: где встречался и как звучит



Сводка от локальной LLM

ЧЕСТНО

Где ещё слабо

Длинные подкасты

В 20-минутном разговоре двух ведущих диаризация отдала одному почти всю речь. Модель голоса их различает (сходство 0,44 против 0,83–0,89) — ломается раньше. Разбираем на стенде.

Дальнее поле

Телефон на столе в комнате или перегруженный микрофон: эхо и клиппинг делают голоса похожими. DER 19–29 %, WER до 25 %.

Декодирование

AAC на Pixel 8 декодируется в 8 раз быстрее реального времени, на эмуляторе — в 66. Переведём на асинхронный MediaCodec.

Все ограничения и замеры — в docs/LIMITATIONS.md и bench/README.md

Мяу!

Спасибо. Готовы ответить на вопросы.

github.com/lapcevichme/meow-scribe

CHUPAPIS · @LAPCEVICHME · @OATIS123

